Universidad Nacional Abierta y a Distancia

Vicerrectoría Académica y de Investigación

Curso: Big Data

Código: 202016911

Guía de aprendizaje– Tarea 3 - Procesamiento de Datos con Apache Spark

1. Datos de la Taller

Tabla 1. Tabla de descripción

Aspecto	Descripción
1. Tipo de actividad	Colaborativa
2. Momento de la evaluación	**Intermedio**
3. Unidad gestora	Escuela de Ciencias Básicas Tecnología e Ingeniería ECBTI
4. Puntaje de la/el Elija un elemento.	**115 puntos**
5. La actividad inicia el:	jueves, 1 de octubre de 2026
6. La actividad finaliza el:	jueves, 29 de octubre de 2026
7. Horas de trabajo independiente del estudiante	24 horas

2. Descripción detallada de la actividad de aprendizaje

Con el desarrollo de esta actividad se espera que se alcance el siguiente resultado de aprendizaje:

- Resultado de aprendizaje 2: Diseñar e implementar soluciones de almacenamiento y procesamiento de grandes volúmenes de datos utilizando herramientas como Hadoop, Spark y Kafka, para desarrollar infraestructuras tecnológicas que soporten el análisis eficiente de datos.

La actividad consiste en:

1. Investigación:

- Elaborar una tabla comparativa que resalte las diferencias clave entre Hadoop y Spark en términos de arquitectura, procesamiento, rendimiento y casos de uso
- Definir los conceptos de RDD. Propiedades de los RDDs: Inmutabilidad, particionamiento. Tipos de Operaciones:
    - Transformaciones: map, filter, flatMap, groupByKey, reduceByKey.
    - Acciones: collect, count, take, reduce.
- Concepto de DataFrame. Diferencias y ventajas sobre los RDDs.
- Crear un diagrama que ilustre la arquitectura de Kafka y explicar los conceptos clave como topics, partitions, brokers, producers y consumers.

2. **Definición del problema y selección de conjunto de datos:** Cada estudiante deberá seleccionar un problema que pueda ser resuelto mediante el análisis de un conjunto de datos de gran volumen.

    - El conjunto de datos puede ser propio o provenir de alguna fuente pública (Kaggle, UCI Machine Learning Repository, datos abiertos de Colombia, etc.).

3. **Implementación en Spark:** Desarrollar una aplicación implementado Spark (utilizando Python) que realicen las siguientes tareas:

    - **Procesamiento en batch:**
        - Cargar el conjunto de datos seleccionado desde la fuente original.
        - Realizar operaciones de limpieza, transformación y análisis exploratorio de datos (EDA) utilizando RDDs o DataFrames.
        - Visualizar los resultados del procesamiento en batch.

    - **Procesamiento en tiempo real (Spark Streaming & Kafka):**
        - Configurar un topic en Kafka para simular la llegada de datos en tiempo real (usar un generador de datos).
        - Implementar una aplicación Spark Streaming que consuma datos del topic de Kafka.

- Realizar algún tipo de procesamiento o análisis sobre los datos en tiempo real (contar eventos, calcular estadísticas, etc.).
- Visualizar los resultados del procesamiento en tiempo real.

Para el desarrollo de este componente practico deberá acceder al siguiente documento:

- **Anexo 3. Instructivo Spark Streaming y Kafka**. Este documento contiene el paso a paso de como instalar y configurar **Apache Streaming y Kafka** para el posterior procesamiento de datos.

4. Documentación y presentación:

- **Foro de discusión:** Compartir los avances del proyecto y socializar el conjunto de datos seleccionado, problemas encontrados y soluciones implementadas.
- **Repositorio de código:** Cada estudiante debe publicar el código fuente del procesamiento en batch en un repositorio Git (GitHub, GitLab, etc.) con una descripción clara de la solución y las instrucciones para su ejecución.
- **Video Explicativo:** Cada estudiante debe crear un video de máximo 5 minutos donde debe mostrar
  - El código desarrollado para en análisis en batch (Spark).
  - Los resultados obtenidos ejecutando el código de análisis en batch(spark).
  - Mostrar el proceso de ejecución y análisis de datos en tiempo real (Kafka y streaming), es decir, la realización del anexo 3.
- **Presentación online:** Cada estudiante deberá elaborar una presentación que incluya:
  - Introducción al problema y explicación del conjunto de datos seleccionado.
  - Enlace del video en el cual explica el código desarrollado para el procesamiento en batch (Spark) y muestra el análisis en tiempo real (Kafka y streaming).
- **Informe escrito (Tarea3_grupo.pdf)**: El documento debe contener:
  - Portada
  - Introducción

- Objetivo General
- Objetivos Específicos
- Respuesta a las actividades de investigación.
- Enlaces de las presentaciones online.
- 5 conclusiones generales del grupo.
- Referencias Bibliográficas

Para el desarrollo de esta actividad se requieren los siguientes materiales y recursos:

- Sebastián Maldonado, C. V. (2022). *Analytics y Big Data. Ciencia de los Datos aplicada al mundo de los negocios*. (P 185-195). RIL editores. https://research-ebsco-com.bibliotecavirtual.unad.edu.co/linkprocessor/plink?id=95f345f8-e764-3b22-a794-13af16d4c429.
- Macías, M. & Gómez, M. (2015). Introducción a Apache Spark: para empezar a programar el big data. (P 27-40). Editorial UOC. https://elibro-net.bibliotecavirtual.unad.edu.co/es/ereader/unad/58454?page=29
- Montoya Suarez, L. & Gil Restrepo, G. A. (2018). Actualidad e importancia de la implementación de Big Data utilizando las herramientas Hadoop y Spark . https://elibro-net.bibliotecavirtual.unad.edu.co/es/ereader/unad/126993?page=1.
- Velázquez Esquivel, C. I., Ruiz Ayala, J., García Muñoz, L. H., & García Villareal, L. J. (2017). Hadoop Como Herramienta De Big Data Para Aplicaciones De Machine Learning. *Congreso Internacional de Investigacion Academia Journals*. https://research-ebsco-com.bibliotecavirtual.unad.edu.co/linkprocessor/plink?id=45acdb77-0fab-3f1f-81b5-f1b9cb23679c.
- Gélvez García, N. Y., Díaz, R. P., & Vera, N. E. (2012). Hadoop descripción e instalación en distribuciones Linux. *Revista Entérese Boletín Científico Universitario*. https://research-ebsco-com.bibliotecavirtual.unad.edu.co/linkprocessor/plink?id=052175d1-0408-33db-9940-8da4a4a6bcf0
- Jaramillo, M. L. - (2024). El big data y sus aplicaciones [Objeto_virtual_de_Aprendizaje_OVA]. Repositorio Institucional

UNAD.
https://repository.unad.edu.co/handle/10596/63442.

Para el desarrollo de esta actividad debe seguir los siguientes pasos:

Paso 1: En el entorno de Información inicial debe:

Revisar la agenda del curso y ajustar sus actividades para realizar la entrega del producto final de acuerdo con la fecha establecida.

Paso 2: En el entorno de Aprendizaje debe:

- Realizar las lecturas recomendadas para cada tema y participar activamente en las actividades propuestas.
- Participar en el foro de la tarea 3 – Procesamiento de Datos con Apache Spark, publicando los avances del proyecto y socializar el conjunto de datos seleccionado, problemas encontrados, soluciones implementadas y la presentación online. Respuesta a las actividades de investigación.
- Revisar el trabajo final para que esté en conformidad con lo solicitado en la guía.

Paso 3: En el entorno de Evaluación debe:

- Realizar la entrega del documento final en formato PDF.

3. Indicaciones para el desarrollo y entrega de las evidencias de aprendizaje.

Las evidencias de aprendizaje son las acciones, productos o procesos observables que se realizan y/o entregan para manifestar las capacidades, habilidades, aptitudes y actitudes adquiridas, y que, a su vez, servirán al docente para verificar y evaluar su desempeño.

Las evidencias para desarrollar independientemente son:

- **Participación en el foro:** Realizar mínimo 2 aportes de calidad, mostrando un análisis profundo del tema y avances de las actividades propuestas en la guía
- **Selección de Conjunto de Datos:** Cada estudiante deberá seleccionar un conjunto de datos

- **Desarrollo de código:** Cada estudiante debe desarrollar un código que permita realizar análisis al conjunto de datos seleccionado (procesamiento en batch) como se realizó en el anexo 2 de la tarea 2.
- **Pruebas y depuración:** Asegurar la funcionalidad del código desarrollado
- **Video Demostración:** Cada estudiante deberá crear dos videos, un video donde muestre el funcionamiento y el análisis en batch del conjunto de datos seleccionado y otro video donde muestre en análisis de los datos en tiempo real usando Apache Kafka y Streaming (desarrollo anexo 3).

Las evidencias para desarrollar colaborativamente son:

- **Entrega del documento final en formato PDF (Tarea3_grupo.pdf):** Un solo documento por grupo con la información completa. El documento debe contener:
  - Portada
  - Introducción
  - Objetivo General
  - Objetivos Específicos
  - Respuesta a las actividades de investigación
  - Enlaces de las presentaciones online.
  - 5 conclusiones generales del grupo.
  - Referencias Bibliográficas

Para su desarrollo y entrega tenga en cuenta las siguientes orientaciones:

1. Todos los integrantes del grupo deben participar con sus aportes en el desarrollo de la actividad.

2. En cada grupo deben elegir un solo integrante que se encargará de entregar el producto solicitado en el entorno que haya señalado el docente.

3. Antes de entregar el producto solicitado deben revisar que cumpla con todos los requerimientos que se señalaron en esta guía de actividades.

4. Solo se deben incluir como autores del producto entregado, a los integrantes del grupo que hayan participado con aportes durante el tiempo destinado para la actividad.

Tenga en cuenta que todos los productos escritos independientes o grupales deben cumplir con las normas de ortografía y con las condiciones de presentación que se hayan definido.

En cuanto al uso de referencias considere que el producto de esta actividad debe cumplir con las normas APA

En cualquier caso, cumpla con las normas de referenciación y evite el plagio académico, para ello puede apoyarse revisando sus productos escritos mediante la herramienta Turnitin que encuentra en el campus virtual.

4. Situaciones de orden académico

Considere que en el acuerdo 029 del 13 de diciembre de 2013, artículo 99, se considera como faltas que atentan contra el orden académico, entre otras, las siguientes: literal e) "El plagiar, es decir, presentar como de su propia autoría la totalidad o parte de una obra, trabajo, documento o invención realizado por otra persona. Implica también el uso de citas o referencias faltas, o proponer citad donde no haya coincidencia entre ella y la referencia" y liberal f) "El reproducir, o copiar con fines de lucro, materiales educativos o resultados de productos de investigación, que cuentan con derechos intelectuales reservados para la Universidad"

Las sanciones académicas a las que se enfrentará el estudiante son las siguientes:

a) En los casos de fraude académico demostrado en el trabajo académico o evaluación respectiva, la calificación que se impondrá será de cero puntos sin perjuicio de la sanción disciplinaria correspondiente.

b) En los casos relacionados con plagio demostrado en el trabajo académico cualquiera sea su naturaleza, la calificación que se impondrá será de cero puntos, sin perjuicio de la sanción disciplinaria correspondiente.